

# Problem Set 1: Predicting Income

Big Data y Machine Learning para Economía Aplicada

Gustavo Adolfo Castillo Álvarez (201812166),  
Alexander Almeida Ramírez (202225165),  
Jorge Luis Congacha Yunda (201920042) y  
Jaime Orlando Buitrago González (200612390)

03 de marzo de 2024

## 1 Introducción

Entre 1991 y 2019, el recaudo del impuesto a la renta aumentó en 7,1 puntos porcentuales (p.p.) dentro de la estructura tributaria de América Latina y el Caribe, consolidándose como la segunda fuente de ingresos (26,6%), después de los impuestos generales sobre bienes y servicios (CEPAL 2023). En contraste, para el último año, Colombia se encontró por encima del promedio de sus pares regionales, pues el impuesto a la renta representó el 32,3% de su estructura tributaria; sin embargo, al compararla con la tributaria de este impuesto, Colombia está lejos del grupo de países más desarrollados del cual hace parte, pues la renta representa el 6,4% del PIB, un valor lejano del promedio de la OCDE (34%).

Más aún para el 2019, el recaudo del impuesto de renta de las personas correspondió a tan sólo al 1,3% del PIB colombiano según la CEPAL (2023). Este nivel de ingresos tributarios es considerablemente bajo y se debe al complejo sistema tributario que permite mayores exenciones y deducciones para quienes tienen ingresos más altos (Fergusson y Hofstetter 2022), al mismo tiempo que las políticas, factores psicológicos, coyunturas económicas y deficiencias administrativas favorecen la evasión y elusión de este impuesto sobre los ingresos (García, Parra, y Rueda 2021).

Cada reforma tributaria ha intentado mejorar los niveles de recaudo en los últimos años, así mismo, los cambios administrativos en la DIAN también han contribuido a este propósito, buscando un sistema tributario más eficiente y progresivo, ya que se cuenta con suficiente información y evidencia para identificar sus principales problemas. No obstante, los comportamientos de las personas, sobre todo aquellos asociados a conductas delictivas (como la elusión y evasión), son más difíciles de identificar ante su carácter ilegal y ético. Instrumentos como el aprendizaje de máquinas (ML en adelante, por sus siglas en inglés) pueden complementar y contribuir a aumentar el recaudo de los impuestos, haciendo visible aquello que las personas buscan ocultar o esconder, es decir, generando predicciones sobre los ingresos de las personas a partir de características individuales, de los hogares, o incluso territoriales.

Ha habido varios ejemplos del uso de técnicas de ML para abordar los retos del recaudo de los impuestos. En Indonesia, a través de modelos predictivos se identificaron potenciales pagos a las deudas por impuestos a partir de los registros administrativos de la autoridad fiscal de ese país (Febriminanto y Wasesa 2022); en Armenia, se pudieron identificar posibles fraudes fiscales a

partir de la información reportada por los compradores y vendedores con herramientas de ML (Baghdasaryan et al. 2022); o en Brasil, Sao Paulo, se identificaron potenciales pagadores, ingresos, el monto de los impuestos y multas a partir de los registros administrativos de autoridad fiscal del municipio (Ippolito y Garcia 2020).

Es por tanto, que en este Problem Set busca predecir el ingreso por hora de los y las bogotanas mediante modelos que aprovechan las herramientas del ML, haciendo uso de la principal encuesta de hogares colombiana. Más específicamente, se utilizó la *Medición de Pobreza Monetaria y Desigualdad* (Sarmiento-Barbieri 2024) del 2018 para Bogotá, un módulo de la *Gran Encuesta Integrada de Hogares* (GEIH) del DANE, la cual no sólo proporciona información sobre el mercado laboral, ingreso de las personas, características socioeconómicas y territoriales, si no a su vez representa una fuente de información confiable en la cual las personas no tienen incentivos a reportar información falsa sobre su ingreso, pues la encuesta es anónima y no tiene una finalidad tributaria.

En este contexto, el presente documento ... (preview of the results an main takeaways)

## 2 Datos

La GEIH es la principal y tal vez más importante encuesta de hogares con la que cuenta Colombia actualmente. Mensualmente, el DANE recolecta información sobre los ingresos y el mercado laboral de una muestra representativa de la población colombiana, de tal manera, que cada mes se obtienen datos sobre el ingreso y mercado laboral para el ámbito nacional, y anualmente para 23 departamentos y Bogotá, sus capitales y áreas metropolitanas, y otros dominios (rural y urbano) (DANE 2019). La operación estadística tiene como resultado una base de datos anual de aproximadamente 750 mil observaciones o personas, 230 mil hogares y 30 mil viviendas, la cual permite realizar cálculos y estimaciones sobre la población colombiana.

Aunque la GEIH recolecta información sobre los ingresos y el mercado laboral de la población, se realizan poco más de 150 preguntas a los encuestados que capturan información demográfica, económica y social, de tal manera que se expanden las posibilidades de la encuesta. Es así como esta base de datos también permite caracterizar la migración, micronegocios, la transición entre la educación y el trabajo, trabajo infantil, tecnologías de la información y la pobreza monetaria (dentro de los módulos más importantes). Este último módulo es importante para el desarrollo del presente Problem Set, ya que el DANE agrega los ingresos salariales y no salariales per cápita de las unidades de gasto (hogares para simplificar), identificando las personas con ingresos superiores e inferiores a las líneas de pobreza e indigencia definidas en el Comité de Expertos <sup>1</sup>. Es así como la GEIH es también la principal fuente de información para calcular la incidencia, brecha y severidad de esta medición del bienestar de la población.

La GEIH y su módulo sobre la *Medición de Pobreza Monetaria y Desigualdad* están disponibles al público en general a través de la Archivo Nacional de Datos (ANDA) del DANE. Sus módulos anonimizados se pueden descargar y unir para la investigación académica, la toma de decisiones o cualquier propósito individual. En este caso, para el Problem Set no se realizó el descargue de la página del DANE, sino se realizó un *web scraping* de la base de datos filtrada para Bogotá, de la página web de Ignacio Sarmiento Barbieri (Sarmiento-Barbieri 2024) como caso práctico de extracción de contenidos de una página web, con un formato estructurado.

---

<sup>1</sup>Personas o representante de entidades nacionales o de cooperación internacional con la experticia técnica para orientar la operación estadística, cálculos y estimaciones de la pobreza monetaria

En la página web se encuentran 10 tablas en formato HTML, las cuales contienen en total las 32.177 observaciones que componen la muestra de personas para Bogotá de la GEIH para 2018, con 179 variables (21 variables adicionales a las presentes en la base de datos del ANDA). Al encontrarse en un formato estructurado (tabla HTML), se realizó el *web scrpaing* haciendo uso del paquete **RSelenium** de **RStudio**, con el cual se automatiza la consulta de cada una de los 10 hipervínculos de la página web, se identifica la tabla en HTML, se almacena y posteriormente se consolida una sola base de datos con las características anteriormente mencionadas.

Como complemento, se descargaron y unieron las bases de datos de la GEIH de 2018 (DANE 2022), de tal manera que se obtuviesen variables complementarias para el desarrollo del Problem Set. Más específicamente, los años de escolaridad, la rama de actividad <sup>2</sup> y la pregunta sobre la posición ocupacional de las personas ocupadas. De esta manera, se obtuvieron variables complementarias como escolaridad como variable continua, experiencia laboral <sup>3</sup>, sector económico y posición ocupacional.

Finalmente, se filtró la base de datos con las personas mayores de 18 años, quedando en total 16.542 observaciones o personas para el desarrollo del Problem Set. De esta manera, a continuación se presentan las estadísticas descriptivas de las variables utilizadas en los siguientes puntos. Como los objetivos asociados al uso de los datos tiene fines predictivos, se prescinde de la variable de los factores de expansión, con los cuales se hace inferencias sobre la población. Por consiguiente, en adelante todos los resultados hacen mención a la muestra de la GEIH.

Statistic	N	Mean	St. Dev.	Min	Median	Max
Ingreso laboral (miles)	9,892	8.822	12.886	0.327	5.056	350.583
Experiencia laboral	16,541	22.011	15.150	0	19	81
Edad	16,542	39.436	13.483	18	38	94
Años de escolaridad	16,541	11.430	4.337	0	11	26

Cuadro 1: Estadísticas descriptivas. Variables continuas

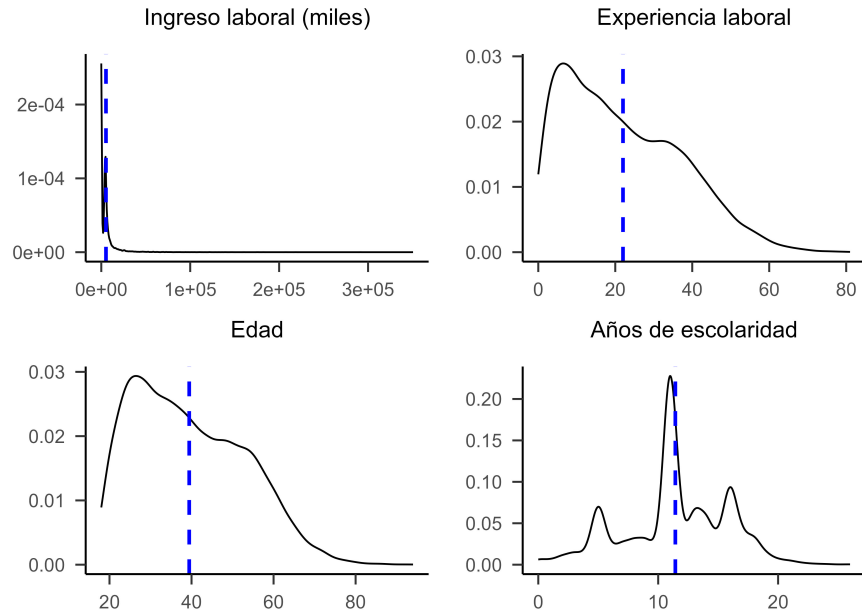
Como se observa en la tabla anterior, tres de las cuatro variables por incluir tienen valores perdidos. La variable ingreso laboral con 6.650 observaciones, y experiencia laboral y años de escolaridad con 1 observación. En el primer caso, siguiendo las recomendaciones de Chen y Roth (2023), se utilizó una transformación logarítmica del salario sumando una unidad, de tal manera que los valores perdidos puedan ser utilizados. Para las otras dos variables, se remplazaron con los valores promedios, toda vez que representa 1 sola observación y se puede asemejar a un individuo representativo de Bogotá. De esta manera, las distribuciones de estas variables con sus ajustes se observan a continuación:

Como se observa en las gráficas de distribución anteriores, la población ocupada vive situaciones de desigualdad. El ingreso se concentra en los niveles más bajos y una muy baja concentración en los ingresos más altos. De igual manera, la mayor parte de la población alcanza hasta 11 grados de escolaridad (culminación de la educación media), con una importante acumulación en la población con 9 años (grado noveno). No obstante, la concentración de la población con 16 años de escolaridad (pregrado universitario) muestra la oportunidad que representa el capital humano acumulado de la ciudad.

<sup>2</sup>Código a dos dígitos de la Clasificación Industrial Internacional Uniforme de todas las actividades Económicas (CIU).

<sup>3</sup>Variable \*proxy\* construida como Edad-Años de escolaridad-Años de ingreso al sistema educativo (6 años)

Figura 1: Distribución variables continuas



En cuanto a la experiencia laboral y la edad tienen una gráfica de distribución similar, dado que la primera es un **proxy** que se construye a partir de la edad y los años de escolaridad. Claro está, para el 2018, se observa que aproximadamente hasta el 75% de la población ocupada es menor de 50 años, con una caída en la curva en la distribución a partir de los 60 años. Esta situación muestra no sólo que una vez se alcanza la edad de pensión, muchas personas probablemente pasan a ser inactivos, sino también una fuerza laboral ocupada principalmente compuesta por población en edad de trabajar, representando una oportunidad para el desarrollo económico y social de Bogotá.

Como variables relevantes para incluir dentro de los modelos para la predicciones se consideraron la posición ocupacional, el sector y desde luego el sexo, cuyos valores absolutos y proporciones se observan en la siguiente tabla. Como se observa, las mujeres tienen un menor acceso al empleo dentro del mercado laboral en comparación a los hombres, pues son representadas el 47% de la población ocupada. En cuanto al sector económico, predomina el comercio con un 37,7% de los ocupados en Bogotá, no es fortuito así encontrar una importante participación de los trabajadores por cuenta propia (30,9%), es decir, dos situaciones que muestran un mercado laboral en el que son propicias las condiciones del empleo informal.

Variable	N	%
Posición ocupacional		
Obrero, empleado particular	9342	56.47
Obrero, empleado del gobierno	632	3.82
Empleado doméstico	578	3.49
Trabajador por cuenta propia	5106	30.87
Patrón o empleador	626	3.78
Trabajador familiar sin remuneración	207	1.25
Trabajador sin remuneración en empresas de otros hogares	41	0.25
Jornalero o Peón	1	0.01
Otro	9	0.05
Sector		
Agricultura, ganadería, caza, silvicultura y pesca	106	0.64
Explotación de Minas y Canteras	50	0.30
Industria manufacturera	2470	14.93
Suministro de Electricidad Gas y Agua	77	0.47
Construcción	881	5.33
Comercio, hoteles y restaurantes	4581	27.69
Transporte, almacenamiento y comunicaciones	1484	8.97
Intermediación financiera	496	3.00
Actividades inmobiliarias, empresariales y de alquiler	2534	15.32
Servicios comunales, sociales y personales	3863	23.35
Sexo		
Hombre	8767	53.00
Mujer	7775	47.00

Cuadro 2: Frecuencias variables categóricas

En su conjunto, los ocupados se emplean en las actividades económicas asociadas a Servicios representan el 84,1% de la población ocupada, por su parte quienes se dedican a las actividades a producción de Bienes son el 15,9% de la población ocupada. Como un equilibrio desde el punto de vista de la oferta, es factible pensar una participación similar de la demanda, es decir, un tejido empresarial bogotano compuesto principalmente por actividades económicas asociadas a los Servicios en la ciudad de Bogotá.

### 3 Modelo

El modelo

### 4 Perfiles de salario por edad

Para empezar a caracterizar los determinantes de los salarios, vamos a realizar una estimación que explore la relación entre ingresos y edad. Existe literatura que encuentra que los salarios tienden a

seguir una distribución de  $u$  invertida, en la que el máximo salario se obtiene a los 50 años. A partir de esta edad, comienza a observarse disminuciones significativas en los salarios (Skirbekk, 2004). Entre las posibles explicaciones de este suceso está relacionado con la productividad. Las personas cuando comienzan su vida laboral tienden a tener menos experiencia y habilidades especializadas, por lo que sus salarios son más bajos al inicio de sus carreras. A partir de algún momento de la edad adulta, las capacidades cognitivas y físicas empiezan a disminuir.

Estudiar esta relación es importante en la medida en que es importante determinar los salarios por edad con el fin de realizar un perfilamiento de los ingresos por grupos de edad. Por tal motivo, se plantea estimar la siguiente regresión por medio de Mínimos Cuadrados Ordinarios para analizar la relación entre salarios y edad:

$$\log(\text{salario}_i) = \beta_0 + \beta_1 \text{Edad} + \beta_2 \text{Edad}^2 + u_i$$

Dónde  $\text{Salario}_i$  corresponde a los ingresos asalariados + independientes total nominal por hora. Se realiza la transformación logarítmica con el fin de facilitar la interpretación de los coeficientes de la regresión. La  $\text{Edad}$  y la  $\text{Edad}^2$  corresponden a la edad para cada individuo  $i$ . La inclusión del término cuadrático permite modelar la relación en  $u$  invertida entre salarios y la edad y el término  $u_i$  corresponde al término error idiosincrático, que representa las variables que no están en nuestro modelo y que explican los salarios.

Sin embargo, debido a que este modelo tiene un posible problema de endogeneidad (en la medida en la que la edad está correlacionada con otras variables como la educación y la experiencia), decidimos hacer un ejercicio adicional, en el que se incluyen controles con el fin de mejorar la inferencia causal. Las variables explicativas que agregamos son: horas trabajadas a la semana, el sexo de los individuos, ocupación, tipo de ocupación y su máximo nivel educativo.

En la tabla tal se pueden observar los resultados de las estimaciones. La columna 1 muestra los resultados de la estimación sin controles, mientras que la columna 2 presenta la regresión con controles. Se puede observar que, en promedio, un aumento de un año en la edad está asociado con un incremento en el salario del 5.5% (modelo sin controles) y del 6.4% (modelo con controles). Estos resultados muestran que nuestra especificación es robusta en la medida en que los resultados no presentan un gran cambio en magnitud. Sin embargo, debido a que estamos estimando una relación no lineal entre la edad y el salario, la interpretación no es tan intuitivamente porque debemos tener en cuenta el  $\beta_2$  de la regresión.

	Logaritmo del salario	
	Con controles	Sin controles
	(1)	(2)
Edad	0.055*** (0.003)	0.064*** (0.002)
Edad al cuadrado	-0.001*** (0.00004)	-0.001*** (0.00003)
Observaciones	14,763	14,763
R <sup>2</sup>	0.023	0.357
R ajustado <sup>2</sup>	0.023	0.357
<i>Note:</i>	*p<0.1; **p<0.05; ***p<0.01	

Cuadro 3: Resultados de la regresión

En cuanto al coeficiente de la variable edad al cuadrado no cambia para ninguno de los modelos. Lo más importante de este coeficiente es su signo negativo. Esto indica que hay una relación cóncava entre el salario y la edad, resultado esperado por la teoría. Para poder interpretar correctamente el coeficiente de la edad, debemos derivar con respecto a la edad:

$$\frac{\partial \log(\text{salario})}{\partial \text{Edad}} = \beta_1 + 2\beta_2 \text{Edad}$$

Encontramos que la interpretación depende del nivel de edad que se analiza. Para realizar el análisis, estimamos la edad promedio de la base de datos (38 años). Encontramos que, para un individuo con una edad de 38 años, un año adicional está asociado con un aumento en el salario del 1.7%. Para la interpretación del  $\beta_0$ , sería como el logaritmo del salario promedio cuando las personas tienen 0 años de edad. Aunque esta puede tener una interpretación poco intuitiva, debido a que nuestra muestra está acotada a personas de 18 años, se interpretaría como el salario promedio cuando los individuos inician su vida laboral.


En cuanto a la interpretación del coeficiente de determinación ( $r^2$ ) nos indica que, aproximadamente, el 2.3% de la variación del logaritmo del salario es explicada por la edad. Aunque este  $r^2$  puede ser bajo, es explicado porque existen muchos más factores que explican el salario. Por esto, cuando vemos el  $r^2$  del modelo con controles, encontramos que el  $r^2$  se incrementa hasta aproximadamente el 34%. Sin embargo, estas variables son significativas a un nivel de significancia del 5%, lo que indica que la edad es un determinante del salario.

Ahora, vamos a encontrar la edad en la que empiezan a disminuir los ingresos de las personas. Para hacerlo, debemos encontrar el punto máximo de la función que estimamos e igualar a cero. Haciendo el procedimiento, obtenemos que esta edad máxima está dada por:  $\text{edad}_{max} = -\beta_1/2\beta_2$ . Reemplazando estos valores en esta ecuación, encontramos que la edad máxima en la que se alcanza el máximo rendimiento de los salarios se alcanzan a los 49.65 años. Este valor es esperado según la literatura (citar literatura).

Para analizar esto mejor, en la figura tal se puede observar la relación entre la edad y los salarios. En la primera mitad de la gráfica, se puede observar que aumentan los salarios a medida que aumenta

la edad. Esto es explicado debido a que las personas cuentan con cada vez más experiencia y habilidades, hasta llegar a su máximo ingreso a los 49.65 años, en los que los incrementos comienzan a disminuir hasta niveles más bajos que los incrementos al comienzo de su vida laboral. Como se discutió al principio de la sección, puede deberse a múltiples razones como un retraso en el aprendizaje de nuevas habilidades por la reducción de capacidad cognitiva, lo que implica tener más dificultad para ascender o encontrar empleos con mayores ingresos.

En la gráfica anterior también se pueden observar los intervalos de confianza al nivel de confianza del 95%. Estos intervalos fueron construidos con errores estándar boottrops, en la que se realizaron 1000 repeticiones de la regresión sin controles con un resampléo de la muestra para cada repetición. Es importante notar que estos intervalos crecen a medida que la edad aumenta, esto puede deberse a que existe mucha heterogeneidad de salarios en las personas con edades mayores, porque, por ejemplo, existen personas con salarios muy altos (con posiciones gerenciales, por ejemplo) mientras que otras personas continuaron con puestos relativamente bajos o que están cerca de la edad de jubilación, por lo que sus salarios disminuirían.



## 5 Brechas de ingreso por sexo

- a) En esta sesión se intenta predecir la brecha salarial del logaritmo del ingreso entre hombres y mujeres. Para ello, comenzamos estimando el modelo más sencillo de todos, es decir, el modelo univariado:

$$\ln(w) = \beta_1 + \beta_2 \text{Mujer} + u \quad (1)$$



Los resultados de la regresión muestran que en promedio, el salario de una mujer es 4,37% menor en comparación con el salario de un hombre. Esto con un nivel de significación del 5% y con un error estándar de 0.733.

	<i>Dependent variable:</i>	
	Ln Salario	
	(1)	(2)
age		0.012*** (0.001)
womanMujer	-0.144*** (0.016)	-0.124*** (0.014)
relab		0.126*** (0.020)
Constant	14.076*** (0.011)	13.898*** (0.192)
Observations	9,964	9,963
R <sup>2</sup>	0.009	0.453
Adjusted R <sup>2</sup>	0.008	0.448
Residual Std. Error	0.775 (df = 9962)	0.579 (df = 9876)
F Statistic	86.083*** (df = 1; 9962)	94.912*** (df = 86; 9876)
<i>Note:</i>		
*p<0.1; **p<0.05; ***p<0.01		
Controles: oficio, maxEduclevel		

Cuadro 4: Estimando brecha de género

El coeficiente  $\beta_2 < 0$  indica que las mujeres, en promedio y ceteris praibus, reciben un salario mensual NA menos ingresos que los hombres.

- B) Para mejorar la estimación anterior se corrió un modelo condicional en donde se incluye controles como características similares de trabajadores y puestos de trabajo. Para ello se recurrió al uso de FWL y FWL con bootstrap.

## 5.1 Estimación FWL:


En la primera etapa, *partialling-out*, ejecutamos dos regresiones. Definimos nuestra variable de interés a la variable dicotómica de *Mujer*. Con esto corremos la primera regresión para estimar  $woman \sim x_1 + x_2 + \dots$ , donde las  $x_i$  son todas aquellas variables de control usadas para corregir el potencial sesgo de variable omitida. Posteriormente nos quedamos con los residuales `woman_res`, y ejecutamos una segunda regresión en la que estimemos  $\log\_wage \sim x_1 + x_2 + \dots$ , y guardamos estos residuales, `log_wage_res`.

Finalmente ejecutamos la segunda regresión univariada `log_wage_res~woman_res` y obtenemos el mismo coeficiente del modelo original con controles. Los resultados dejan ver que una vez incorporado controles a la regresión de gap, se tiene que el salario de las mujeres es en promedio menor en 16.5% respecto al salario del hombre, *ceteris paribus*.

## 5.2 Estimación FWL con bootstrap:

Por otra parte, estimando el modelo con FWL y bootstrap se puede apreciar que el valor del gap es el mismo del modelo anterior, es decir, el gap es del 16.54%. Con este obtenemos el mismo valor de gap, sin embargo el valor del error estandar para la estimación con FWL y Bootstrap es menor, siendo este de 0.0122. Esta diferencia se da debido a que FWL asume que su modelo es homocedástico, lo cual no es verdadero.

Figura 2: Perfil de ingresos vs edad por sexo



c)

Fuente: Cálculos propios a partir de @geih

Para identificar las edades en las que tanto hombres como mujeres alcanzan sus mayores ingresos laborales, realizamos dos análisis por separado: uno para hombres y otro para mujeres. Primero, ajustamos modelos de regresión a los datos de cada grupo y luego realizamos las predicciones correspondientes. Se usó la técnica de bootstrap para calcular los valores de los picos de ingresos, representados por la fórmula

$$\frac{-B_1}{2 \cdot B_2}$$

, junto con sus intervalos de confianza. Los resultados de ambas regresiones son estadísticamente significativos, lo que indica que la edad explica parte de la variabilidad en el logaritmo de los salarios, todavía queda una parte considerable de la variabilidad que no se explica.

Al observar la gráfica, observamos que la edad pico para los hombres es de 47.96018, mientras que para las mujeres es de 42.64015. Esta diferencia señala una disparidad significativa en las edades donde ambos géneros alcanzan sus máximos ingresos laborales. Además, los intervalos de confianza de ambas edades no se superponen, lo que sugiere una distinción clara entre ambos grupos.

Sin embargo, dado que la gráfica solo considera la edad y el coeficiente de determinación  $R^2$  es bajo, es probable que la inclusión de más variables predictivas mejore considerablemente la capacidad de predicción.

## 6 Predicción de salarios

## 7 Referencias bibliográficas

- Baghdasaryan, V., H. Davtyan, A. Sarikyan, y Z. Navasardyan. 2022. «Improving Tax Audit Efficiency Using Machine Learning: The Role of Taxpayer's Network Data in Fraud Detection». *Applied Artificial Intelligence* 36 (1): 2012002. <https://doi.org/10.1080/08839514.2021.2012002>.
- CEPAL. 2023. *Panorama fiscal de América Latina y el Caribe 2023*. CEPAL.
- Chen, J., y J. Roth. 2023. «Logs with Zeros? Some Problems and Solutions». *The Quarterly Journal of Economics*, diciembre, qjad054. <https://doi.org/10.1093/qje/qjad054>.
- DANE. 2019. «Medición de Pobreza Monetaria y Desigualdad 2018». [Base de datos].<https://microdatos.dane.gov.co/index.php/catalog/608>
- DANE. 2022. «Gran Encuesta Integrada de Hogares 2018. Empalmada». [Base de datos].<https://microdatos.dane.gov.co/index.php/catalog/758>
- Febriminanto, R., y M Wasesa. 2022. «Machine Learning Analytics for Predicting Tax Revenue Potential». *Indonesian Treasury Review* 7 (3): 193-205.
- Fergusson, L., y M. Hofstetter. 2022. «The Colombian tax system: A diagnostic review and proposals for reform». UNDP.
- García, M., O. Parra, y F. Rueda. 2021. «Features of tax structure and tax evasion in Colombia». *Apuntes Contables*, n.º 28: 17-40.
- Ippolito, A., y A. Garcia. 2020. «Tax Crime Prediction with Machine Learning: A Case Study in the Municipality of Sao Paulo». *ICEIS 2020* 1: 452-59.
- Sarmiento-Barbieri, I. 2024. «Problem Set 1. BDML». [Base de datos].[https://ignaciomsarmiento.github.io/GEIH2018\\_sample/](https://ignaciomsarmiento.github.io/GEIH2018_sample/)

## 8 Ejemplos

Para incrustar código y resultados de la consola

```
summary(cars)
```

```
##      speed      dist
##  Min.   : 4.0    Min.   :  2.00
##  1st Qu.:12.0    1st Qu.: 26.00
##  Median :15.0    Median : 36.00
##  Mean   :15.4    Mean    : 42.98
```


```
## 3rd Qu.:19.0 3rd Qu.: 56.00
## Max. :25.0 Max. :120.00
```

Para incluir ecuaciones

$$w = f(X) + u$$

Para incluir gráficas

Figura 3: Título de la gráfica



Fuente: Cálculos propios a partir de @geih